

Reference-Relative Generative Information Design

问题、算法、核心理论与首阶段实验计划

研究规格草案（中文，面向 ICLR 方法型论文）

2026 年 8 月

摘要

本文整理当前冻结版本的 Reference-Relative Generative Information Design (RR-GID)。已有完整 reference population，并训练得到冻结的高维生成器 G_0 ；新的 target population 每个独立 unit 只能测量一个受限 panel。目标不是补全单个样本，而是在固定 measurement budget 下恢复 target 的完整联合分布。我们用 reference-relative exponential tilt 建模 target shift，利用 reference generator 的完整条件结构计算 panel 对 relative-score directions 的 Fisher information，并由 full-target KL 风险导出最优 allocation。算法仅包含 balanced pilot、一次 generator-aware design、主数据采集和少量 Fisher-scoring 更新。本文给出当前主理论包的严格陈述，并将首阶段实验压缩为一个可解析的 nonlinear synthetic benchmark 与一个 Gas Sensor Drift 真实数据集，重点验证 statistical optimality、nonlinear conditional information 与 generator reuse。

一句话：reference generator 不负责把 target 缺失坐标当成真值补全；它提供 $Q_0(X_{S^c} | X_S)$ 这一可复用 conditional-law interface，用来评估“测这个 panel 能对完整 target shift 提供多少信息”，从而把有限 target budget 花在最有价值的测量上。

1 背景与 Motivation

现实中常见如下结构：历史/reference 总体已有完整高维数据，因此可以训练较强的生成模型；但后续 target 总体的完整测量昂贵、耗时或有受访负担，每个新 unit 只能测量少量变量。例如多传感器系统中只能激活少量传感器，或 split questionnaire 中每个受访者只回答一部分问题。

直接用 reference generator 对 target 未测变量做 imputation 并不能解决根本问题：即使 Q_0 已知，如果 target 可以沿任意不可观测方向变化，合法 panels 的 marginals 也可能完全相同而完整 target law 不同。因此必须限制 reference 到 target 的相对变化；同时，测量设计应针对这些允许的 shift directions，而不是只追求变量覆盖或 pairwise correlation。

本文采用低维 relative tilt，但允许 Q_0 本身保持复杂 multimodality、高阶依赖和非线性 conditional structure。与 classical split-questionnaire OED 相比，关键变化在于：panel value 不再由 Gaussian covariance 决定，而由完整 relative score 在 $\sigma(X_S)$ 上的条件投影决定；与一般 active feature acquisition 不同，本问题是 **population-level prospective allocation**，panel 在当前 unit 到来前决定，最终目标是 full target law 而非单个 downstream prediction。

2 Formal Formulation

完整变量

$$X = (X_1, \dots, X_d) \in \mathcal{X}.$$

冻结 reference generator G_0 诱导分布 Q_0 。理论不要求解析 density，只要求可从 Q_0 full sampling，并可近似从任意合法 panel 的 conditional law $Q_0(X_{S^c} | X_S = x_S)$ 采样。

在 target campaign 开始前固定 feature map

$$\phi: \mathcal{X} \rightarrow \mathbb{R}^r,$$

并定义 relative exponential family

$$\frac{dQ_\beta}{dQ_0}(x) = \exp\{\beta^\top \phi(x) - A(\beta)\}, \quad A(\beta) = \log \mathbb{E}_{Q_0} e^{\beta^\top \phi(X)}. \quad (1)$$

主理论假设真实 target 为 $Q^* = Q_{\beta^*}$ 。 ϕ 限制的是 reference $\rightarrow$ target 的变化，而不是 Q_0 的复杂度。

合法 panel family 为 $\mathcal{S}$ 。第 i 个 target unit 到来前, 根据历史选择 $S_i \in \mathcal{S}$, 随后只观察 X_{i,S_i} ; 满足 prospective 条件 $X_i \perp S_i \mid H_{i-1}$ 。总成本 $\sum_i c(S_i) \leq B$ 。最终输出 $Q_{\hat{\beta}_B}$, 目标最小化

$$\mathbb{E} \text{KL}(Q_{\beta^*} \| Q_{\hat{\beta}_B}).$$

第一版理论采用: 有限 $\mathcal{S}$, $0 < c_{\min} \leq c(S) \leq c_{\max}$; β^* 位于紧致参数集内部; ϕ 有界(之后可放宽为局部 exponential moment); exponential family minimal; 并存在某 allocation 使所有 shift directions collectively observable。

3 Generator-Aware Information Geometry

完整 score 与 full Fisher information 为

$$s_\beta(X) = \phi(X) - \mu_\beta, \quad \mu_\beta = \mathbb{E}_\beta \phi(X), \quad F(\beta) = \text{Var}_\beta(\phi(X)). \quad (2)$$

只观察 X_S 时, panel marginal score 恰为

$$m_{\beta,S}(x_S) = \mathbb{E}_\beta[s_\beta(X) \mid X_S = x_S], \quad (3)$$

其 Fisher information 为

$$I_S(\beta) = \text{Var}_\beta\{m_{\beta,S}(X_S)\}. \quad (4)$$

若 p_S 表示总测量成本中分给 panel S 的比例, 则单位成本 information

$$M_\beta(p) = \sum_{S \in \mathcal{S}} \frac{p_S}{c(S)} I_S(\beta), \quad p \in \Delta_{\mathcal{S}}. \quad (5)$$

为什么不是 covariance。 对任意方向 v , 令 $Y_v = v^\top s_\beta(X)$ 。有变分表征

$$v^\top I_S v = \sup_{g \in L_2(X_S)} \{2\mathbb{E}[g(X_S)Y_v] - \mathbb{E}[g(X_S)^2]\}. \quad (6)$$

对任意受限 predictor class $\mathcal{G}_S$, restricted information 与 full information 的精确 gap 为

$$v^\top I_S v - \mathcal{I}_{S,\mathcal{G}}(v) = \inf_{g \in \mathcal{G}_S} \mathbb{E}[g(X_S) - \mathbb{E}(Y_v \mid X_S)]^2. \quad (7)$$

因此 linear/covariance design 只是取 $\mathcal{G}_S$ 为线性函数的特例; 完整 conditional law 对应 unrestricted endpoint。

4 算法: Formal Pilot-Design-Update RR-GID

本节给出与理论对象一一对应的 formal algorithm。设 $A_a \subseteq [d]$ 为 feature ϕ_a 的最小坐标 support。除 G_0 的 full/conditional sampling 外, 算法使用两个由 reference generator 诱导的 tilted sampling primitives:

$$\text{TiltFull}(\beta): X \sim Q_\beta, \quad \text{TiltCond}(\beta, S, x_S): X_{S^c} \sim Q_\beta(\cdot \mid X_S = x_S).$$

它们可由 Q_0 full/conditional proposals 加权或 accept-reject 得到; 理论将其视为 exact oracle, 有限 Monte Carlo 误差在 supporting theory 中单独处理。对实际 target observation $y = x_S$, 记

$$m_{\beta,S}(y) = \mathbb{E}_\beta[s_\beta(X) \mid X_S = y], \quad s_\beta(X) = \phi(X) - \mu_\beta.$$

4.1 Monte Carlo 子程序与预算离散化

Reference log-partition approximation。 先固定一个独立 reference pool $\{X_0^{(r)}\}_{r=1}^{R_A} \stackrel{\text{iid}}{\sim} Q_0$, 定义

$$\hat{A}_{R_A}(\beta) = \log \left\{ \frac{1}{R_A} \sum_{r=1}^{R_A} \exp(\beta^\top \phi(X_0^{(r)})) \right\}. \quad (8)$$

在 oracle synthetic 中可用解析/高精度 A ; 在 learned-generator 实验中统一使用 Equation (8)。

Panel information estimator. 给定参数 β , 先采 N_g 个 full tilted samples $Z_n \sim Q_\beta$, 记

$$\hat{\mu}_\beta = \frac{1}{N_g} \sum_{n=1}^{N_g} \phi(Z_n), \quad \hat{F}_\beta = \frac{1}{N_g - 1} \sum_{n=1}^{N_g} (\phi(Z_n) - \hat{\mu}_\beta)(\phi(Z_n) - \hat{\mu}_\beta)^\top.$$

对每个 $S \in \mathcal{S}$, 令 $Y_{S,n} = (Z_n)_S$. 条件于同一 $Y_{S,n}$, 独立生成两批

$$X_{S,n,\ell}^{(a)} \sim Q_\beta(\cdot \mid X_S = Y_{S,n}), \quad a \in \{1, 2\}, \ell = 1, \dots, L_I,$$

并定义

$$\bar{s}_{S,n}^{(a)} = \frac{1}{L_I} \sum_{\ell=1}^{L_I} \{\phi(X_{S,n,\ell}^{(a)}) - \hat{\mu}_\beta\}.$$

令 $\bar{s}_S^{(a)} = N_g^{-1} \sum_n \bar{s}_{S,n}^{(a)}$, 则使用对称 cross-covariance

$$\tilde{I}_S(\beta) = \frac{1}{2(N_g - 1)} \sum_{n=1}^{N_g} \left[(\bar{s}_{S,n}^{(1)} - \bar{s}_S^{(1)})(\bar{s}_{S,n}^{(2)} - \bar{s}_S^{(2)})^\top + (1 \leftrightarrow 2) \right]. \quad (9)$$

理论上 $\mathbb{E}\tilde{I}_S = I_S$. 数值优化时可令 $\hat{I}_S = \Pi_{\mathcal{S}_+^*}(\tilde{I}_S)$; 该 PSD projection 仅用于 finite-sample stability.

Cost-share rounding. 设计变量 p_S 表示**总成本份额**而非 unit-level sampling probability. 给定可用预算 B' , 实现时取

$$n_S(B', p) = \left\lfloor \frac{B' p_S}{c(S)} \right\rfloor, \quad (10)$$

剩余不足一个 panel 的预算可忽略, 或按 fractional remainder 从大到小补齐; 无论哪种实现均满足 $n_S c(S)/B' = p_S + O(B'^{-1})$.

4.2 Cost-aware design solver

给定 $\hat{F} \succ 0$ 与 $\{\hat{I}_S\}$, 定义

$$\widehat{M}(p) = \sum_{S \in \mathcal{S}} \frac{p_S}{c(S)} \hat{I}_S, \quad \widehat{\Phi}(p) = \text{tr}\{\hat{F} \widehat{M}(p)^{-1}\}.$$

选择一个已知可观测的 safe allocation p^{safe} 使 $\widehat{M}(p^{\text{safe}}) \succ 0$. Frank-Wolfe 的 sensitivity 为

$$\gamma_S(p) = \frac{1}{c(S)} \text{tr}\{\widehat{M}(p)^{-1} \hat{F} \widehat{M}(p)^{-1} \hat{I}_S\}, \quad (11)$$

并有 certificate $g_{\text{FW}}(p) = \max_S \gamma_S(p) - \widehat{\Phi}(p)$.

Input: $\hat{F}$; $\{\hat{I}_S, c(S)\}_{S \in \mathcal{S}}$; safe allocation p^{safe} ; tolerance $\tau_{\text{FW}} > 0$

Output: $\hat{p}$ and certificate $g_{\text{FW}}(\hat{p})$

$p^{(0)} \leftarrow p^{\text{safe}}; t \leftarrow 0$

repeat

$M_t \leftarrow \sum_S p_S^{(t)} \hat{I}_S / c(S); \Phi_t \leftarrow \text{tr}(\hat{F} M_t^{-1})$
 $\gamma_S^{(t)} \leftarrow c(S)^{-1} \text{tr}(M_t^{-1} \hat{F} M_t^{-1} \hat{I}_S)$ for every $S \in \mathcal{S}$
 $S_t \leftarrow \arg \max_{S \in \mathcal{S}} \gamma_S^{(t)}; g_t \leftarrow \gamma_{S_t}^{(t)} - \Phi_t$
if $g_t > \tau_{\text{FW}}$ **then**
 $\eta_t \leftarrow \arg \min_{\eta \in [0,1]} \widehat{\Phi}((1-\eta)p^{(t)} + \eta e_{S_t})$
 $p^{(t+1)} \leftarrow (1-\eta_t)p^{(t)} + \eta_t e_{S_t}; t \leftarrow t+1$
end

until $g_t \leq \tau_{\text{FW}}$

return $\hat{p} \leftarrow p^{(t)}, g_{\text{FW}}(\hat{p}) \leftarrow g_t$

Algorithm 1: Cost-aware Frank-Wolfe design solver

4.3 完整 RR-GID 伪代码

Pilot 采用 deterministic balanced counts, 而不是把 cost share 误当成 unit-level probability. 给定 pilot safe allocation p^{bal} , 先用 Equation (10) 得到 $n_S^0 = n_S(b, p^{\text{bal}})$, 令 $n_0 = \sum_S n_S^0$, 并对 feature a 定义实际 pilot coverage frequency

$$\rho_a = \frac{1}{n_0} \sum_{S \in \mathcal{S}} n_S^0 \mathbf{1}\{A_a \subseteq S\} > 0. \quad (12)$$

因此下述 HT moment estimator 在 prospective sampling 下严格无偏。

Input: reference generator G_0 ; feature map $\phi = (\phi_1, \dots, \phi_r)$ and supports $\{A_a\}$; parameter set Θ ; panels $\mathcal{S}$ and costs c ; total budget B ; pilot budget b ; balanced/safe allocation p^{bal} ; MC sizes (R_A, N_g, L_I, L_U) ; scoring steps J ; FW tolerance τ_{FW}

Output: design $\hat{p}$; integer panel counts $\{n_S^0 + n_S^1\}$; estimator $\hat{\beta}_B$; target generator $Q_{\hat{\beta}_B}$

1. **Reference preparation.** Draw $\{X_0^{(r)}\}_{r=1}^{R_A} \sim Q_0$ once and construct $\hat{A}_{R_A}(\beta)$ by Equation (8).

2. **Balanced pilot.** Set $n_S^0 \leftarrow \lfloor bp_S^{\text{bal}}/c(S) \rfloor$ and collect n_S^0 independent target units under each S . Let $\mathcal{D}_0 = \{(S_i, Y_i)\}_{i=1}^{n_0}$, $Y_i = X_{i, S_i}$. Compute ρ_a by Equation (12) and

$$\hat{\mu}_a^{\text{pil}} \leftarrow \frac{1}{n_0} \sum_{i=1}^{n_0} \frac{\mathbf{1}\{A_a \subseteq S_i\}}{\rho_a} \phi_a(X_i), \quad a = 1, \dots, r,$$

where $\phi_a(X_i)$ is evaluated only when $A_a \subseteq S_i$.

$\tilde{\beta} \leftarrow \arg \min_{\beta \in \Theta} \{\hat{A}_{R_A}(\beta) - \beta^\top \hat{\mu}^{\text{pil}}\}$.

3. **Generator-aware information at $\tilde{\beta}$.** Using TiltFull and TiltCond, compute $\hat{F}(\tilde{\beta})$ and $\{\hat{I}_S(\tilde{\beta})\}_{S \in \mathcal{S}}$ by Equation (9).

4. **Design once.** Run the preceding Frank–Wolfe solver with $p^{\text{safe}} = p^{\text{bal}}$ and obtain $\hat{p}$ satisfying $g_{\text{FW}}(\hat{p}) \leq \tau_{\text{FW}}$.

5. **Main campaign.** Set $B_1 \leftarrow B - \sum_S n_S^0 c(S)$ and $n_S^1 \leftarrow \lfloor B_1 \hat{p}_S / c(S) \rfloor$. Collect n_S^1 new independent target units for each S ; let $\mathcal{D}_1$ denote these observations and $\mathcal{D}_B \leftarrow \mathcal{D}_0 \cup \mathcal{D}_1$.

6. **J -step relative-shift update.** Set $\beta^{(0)} \leftarrow \tilde{\beta}$.

for $j = 0, \dots, J-1$ do

Using TiltFull($\beta^{(j)}$), estimate $\hat{\mu}_j \approx \mu_{\beta^{(j)}}$. For every active panel S , re-estimate $\hat{I}_{j,S} \approx I_S(\beta^{(j)})$ by cross-completion.

For each $(S_i, Y_i) \in \mathcal{D}_B$, draw L_U independent completions $X_{i,\ell}^{(j)} \sim Q_{\beta^{(j)}}(\cdot \mid X_{S_i} = Y_i)$ and set

$$\hat{m}_i^{(j)} \leftarrow \frac{1}{L_U} \sum_{\ell=1}^{L_U} \phi(X_{i,\ell}^{(j)}) - \hat{\mu}_j.$$

$\hat{U}_j \leftarrow \sum_{(S_i, Y_i) \in \mathcal{D}_B} \hat{m}_i^{(j)}$; $\hat{H}_j \leftarrow \sum_{S \in \mathcal{S}} (n_S^0 + n_S^1) \hat{I}_{j,S}$.

$\beta^{(j+1)} \leftarrow \Pi_{\Theta} \{\beta^{(j)} + \hat{H}_j^{-1} \hat{U}_j\}$.

end

7. **Return.** $\hat{\beta}_B \leftarrow \beta^{(J)}$ and $dQ_{\hat{\beta}_B}/dQ_0 \propto \exp\{\hat{\beta}_B^\top \phi(X)\}$.

Algorithm 2: Formal Pilot–Design–Update RR-GID

与理论版本的对应。主 T3/T4 使用 exact observed score, 或令 update-stage $L_U = L_{U,B} \rightarrow \infty$, 且 generator information estimation error 为 $o_p(1)$ 。固定 L_U 时, 算法仍一致地实现一个 simulated estimating equation, 但最终 asymptotic covariance 变为 sandwich

$$M(p)^{-1} V_{L_U}(p) M(p)^{-1}, \quad V_{L_U}(p) = \sum_S \frac{p_S}{c(S)} [I_S + L_U^{-1} (F - I_S)].$$

Design-stage 的 cross-completion 则对任意固定 $L_I \geq 1$ 都消除了 I_S 的 Monte Carlo upward bias。

5 核心理论结果

以下仅列主文应强调的结果。support-size、basis invariance、Frank–Wolfe certificate、learned-generator perturbation 等均作为 supporting propositions。

5.1 识别边界与 conditional information

若 observable space

$$\mathcal{O} = \text{span}\{g(X_S) : S \in \mathcal{S}, g \in L_2(Q_{0,S})\}$$

存在非零有界 $h \in L_2^0(Q_0) \cap \mathcal{O}^\perp$, 则 $dQ_\pm/dQ_0 = 1 \pm \epsilon h$ 在所有合法 panel 上有相同 marginals, 但 $Q_+ \neq Q_-$ 。因此 reference 本身不能识别 arbitrary target shift。

在 relative family 内, $M_\beta(p) \succ 0$ 当且仅当不存在 $v \neq 0$ 使 $\mathbb{E}_\beta[v^\top s_\beta(X) \mid X_S] = 0$ 对所有 active panels 成立; Equation (6)–(7)进一步刻画不同 predictor classes 丢失多少 information。

5.2 Full-KL local asymptotic minimax optimality

对 cost-normalized panel counts 收敛到 p , partial-panel experiment 在 local alternative $\beta^* + h/\sqrt{B}$ 下满足 LAN, 极限 information 为 $M_{\beta^*}(p)$ 。由于

$$\text{KL}(Q_\beta \| Q_{\beta+u}) = \frac{1}{2} u^\top F(\beta) u + O(\|u\|^3),$$

正确的 Hájek–Le Cam local asymptotic minimax constant 为

$$\boxed{\frac{1}{2} \text{tr}(F(\beta^*) M_{\beta^*}(p)^{-1})}. \quad (13)$$

对 regular efficient estimator, 在二阶矩一致可积条件下,

$$\mathbb{E} \text{KL}(Q_\beta \| Q_{\hat{\beta}_B}) = \frac{1}{2B} \text{tr}(F M^{-1}) + o(B^{-1}).$$

故 oracle design 正是

$$p^* \in \arg \min_p \Phi_{\beta^*}(p), \quad \Phi_\beta(p) = \text{tr}(F(\beta) M_\beta(p)^{-1}). \quad (14)$$

5.3 一次设计即可达到 oracle first-order efficiency

令 pilot budget $b_B = B^\gamma$ (实践中可乘固定常数), $0 < \gamma < 1$ 。若 $\tilde{\beta} - \beta^* = O_p(B^{-\gamma/2})$, generator information estimates 与 design optimization 一致, 则

$$\Phi_{\beta^*}(\tilde{p}) \rightarrow_p \min_p \Phi_{\beta^*}(p).$$

从 $\tilde{\beta}$ 做 J 次 Fisher scoring 有

$$\|\beta^{(J)} - \beta^*\| = O_p(B^{-1/2} + B^{-2^J \gamma/2}). \quad (15)$$

因此只要 $2^J \gamma > 1$, 最终达到 Equation (13) 的 oracle first-order constant。例如 $\gamma = 1/3$ 时两次 scoring 足够。

5.4 为什么 full conditional structure 值得学习

对任意 fixed order q 与任意 K , 可构造 K 个 full-support reference worlds, 使它们所有至多 q 个坐标的 marginals 完全相同, 但 optimal panel 分别是 K 个不同 panels。任何只依赖这些 bounded-order marginals 的 design rule 必须在所有 worlds 输出同一 allocation, 因此至少有一个 world 满足

$$\frac{\Phi(p_{\text{bounded-order}})}{\Phi(p^*)} \geq K. \quad (16)$$

由于 K 任意, fixed-order summaries 没有有限的 uniform approximation ratio。

另一方面, 在 $\beta = 0$ 时

$$m_{0,S}^h(x_S) = \mathbb{E}_0[h(X) \mid X_S = x_S] - \mathbb{E}_0 h(X).$$

若一个 oracle 能对 measure-determining function class 中所有 post-hoc h 回答上述 conditional-score query, 则这些 conditional expectations 唯一确定 $Q_0(X_{S^c} \mid X_S)$; 反方向显然。因此 universal conditional-score access 与 conditional-law access 在信息意义上等价。这解释了为什么 frozen conditional generator 是跨 ϕ 、panel 与 target campaign 复用的自然接口, 但并不声称单个固定任务上 generator 必然优于强 discriminative regressor。

6 首阶段实验: 目标与统一比较方法

首阶段只做一个 synthetic 主环境和一个真实数据集。所有主结果统一比较四种 acquisition policies:

Reference-Relative Generative Information Design

实验定稿：主结果、机制分析、真实数据与校准附录

RR-GID 实验定稿 2026-09-13

相对 2026-08-20 八页草稿的实验落地说明。理论章节仍见原稿第 1–5 节。本节报告已完成并 fail-closed 审计通过的正文实验。原稿中的 VAEAC、exact oracle、 J 消融、Gas 50 replication、以及 C2ST/RMSE 主表，按 2026-09-02 重规划不再作为正文主结果。

1 实际执行协议

正文只回答三个问题：固定预算下 RR-GID 是否降低 target 全分布误差；优势是否来自非线性条件信息；冻结生成器能否跨 campaign 复用。真实数据只验证 drift 下是否仍成立。

统一指标。 合成数据主指标为

$$R_{\text{risk}} = \frac{B \cdot \text{KL}(Q_{\beta^*} \| Q_{\hat{\beta}})}{C^*}, \quad C^* = \frac{1}{2} \Phi_{\beta^*}(p^*),$$

越低越好， $R_{\text{risk}} = 1$ 为 oracle 一阶效率参考。Gas 主指标为 family-projection loss $D_{\hat{A}}(\hat{\beta}, \beta^\dagger)$ 。

后端, 而非 exact oracle。 全部 bulk 使用 validated fixed/cached QMC: score order 14, information order 12. order-14 cached 与 fixed 的最大绝对差为 6.0×10^{-9} 。正文不得写成 exact oracle。

生成器。 合成数据使用冻结 GMM+warp 条件 oracle。Gas 原稿拟用 VAEAC，但 VAEAC 未过 RISK-2/3。工程等价替换为冻结经验 k NN（与 RISK-2 参考算子相同，Spearman = 1、top-10 overlap = 10/10）。C2ST 对 ref_val 约 0.48–0.53。正文必须写明：Gas 生成器是冻结经验 k NN，不是 VAEAC。

格子。 E1: 200 paired replications, $B \in \{2000, 4000, 8000, 16000, 32000\}$, $J = 2$ 。E2: 15 replications, $B = 8000$, $\alpha \in \{0, 0.5, 1.0, 1.5\}$, $J = 4$ 。E3: 5 sequence $\times$ 50 campaign, $T \in \{1, 5, 20, 50\}$, RR-GID vs Discriminative Score OED。E5: R1/R2 各 20 replications。E4: 最小校准，不进主图。

2 Figure 1: 合成主结果




图 1: 合成主实验 (E1)。横轴 target budget B , 纵轴 R_{risk} 。200 个配对 replication。RR-GID 全程低于 Uniform; A-OSQD 与 Discriminative Score OED 在该格子上不优于 Uniform。

最大预算 $B = 32000$ (Table 1a): RR-GID 均值 1.88, Uniform 3.35, 相对改善 43.9%, 配对 bootstrap 95% CI 为 $[1.23, 1.72]$ (对 paired difference, 不含 0)。A-OSQD 7.51、Disc 5.06, 均差于 Uniform。不要把自适应政策写成全面优于均匀设计。

3 Figure 2: 非线性与生成器复用




图 2: 左: 非线性强度 α (E2, 15 rep)。右: 冻结生成器复用 (E3, 5 sequence)。

E2 中 RR-GID 在 $\alpha \leq 1$ 贴着一阶参考 (0.93/1.04/0.96); $\alpha = 1.5$ 升至 1.80, 仍低于 Uniform 2.78 与 Disc 3.47。A-OSQD 在强非线性崩溃 (6.26)。这支持机制 A: 优势来自非线性条件信息, 而不是协方差信息。

E3 在 $T = 50$: RR-GID 1.06 vs Disc 1.21。Disc 在 $T = 1$ 与 $T = 20$ 方差很大 ($T = 20$ 均值 4.69, SE 2.66)。仅 5 条 sequence, 正文只报告趋势, 不报告精确倍数。

4 Figure 3: Gas Sensor Drift




图 3: 上左: R1 well-specified 半合成。其余三格: R2 自然 drift (batch 7、8-9、10)。纵轴 family-projection loss。

R1 四方法 CI 重叠。 $B = 3200$: Disc 0.419、RR-GID 0.425、Uniform 0.429。well-specified 设定下没有可报告的赢家。

R2 是主故事。相对 Uniform, RR-GID 在多数 campaign $\times$ 大预算更低, 例如 batch 7、 $B = 1600$: 0.053 vs 0.061; batch 10、 $B = 3200$: 0.034 vs 0.038。Discriminative Score OED 仍是强基线, 不写成碾压。

5 Table 1: 最大预算汇总

只报告最大 B 的 primary loss、相对 Uniform 的配对改善、以及 95% 配对 bootstrap CI。设计比 R_{design} 在合成格子上由共享 target draw 决定, 方法间相同, 不作为区分证据。

表 1: Table 1a. 合成主实验, $B = 32000$, $n = 200$ 。loss 为 R_{risk} 。CI 为相对 Uniform 的配对差。

方法	loss	Δ vs Uniform	CI low	CI high
Uniform SQD	3.346	0.0%	0.000	0.000
A-OSQD	7.514	-124.5%	-4.809	-3.560
Discriminative Score OED	5.062	-51.3%	-2.261	-1.217
RR-GID	1.876	+43.9%	1.229	1.717

表 2: Table 1b. Gas R1 半合成, $B = 3200$, $n = 20$ 。loss 为 projection loss。配对 CI 含 0, 与 Figure 3 上左一致。

方法	loss	Δ vs Uniform	CI low	CI high
Uniform SQD	0.4290	0.0%	0.000	0.000
A-OSQD	0.4302	-0.3%	-0.009	0.006
Discriminative Score OED	0.4190	+2.3%	-0.004	0.027
RR-GID	0.4248	+1.0%	-0.010	0.015

表 3: Table 1c. Gas R2 自然 drift, $B = 3200$, 每格 $n = 20$ 。

campaign	方法	loss	vs Uniform
batch 7	Uniform SQD	0.0570	—
batch 7	A-OSQD	0.0541	更低
batch 7	Discriminative Score OED	0.0555	更低
batch 7	RR-GID	0.0539	最低
batches 8-9	Uniform SQD	0.0602	—
batches 8-9	A-OSQD	0.0552	更低
batches 8-9	Discriminative Score OED	0.0522	最低
batches 8-9	RR-GID	0.0531	更低
batch 10	Uniform SQD	0.0380	—
batch 10	A-OSQD	0.0362	更低
batch 10	Discriminative Score OED	0.0361	更低
batch 10	RR-GID	0.0339	最低

6 诚实限制

- 合成主结果用 validated fixed-QMC, 不是 exact oracle。
- Gas 生成器是冻结经验 k NN。RISK-2 Spearman = 1 是因为候选算子与参考算子相同, 不是对 VAEAC 的外推验证。
- E3 只有 5 条 sequence, Disc 的 CI 很宽。
- R1 well-specified 下四方法不可分; 真实数据故事在 natural drift。
- 原稿 Fig. 4 (C2ST / information fidelity 主图) 与 $J \in \{0, 1, 2\}$ 消融已从正文移除, 校准只放附录。

A E4: 最小 oracle calibration

Query 级 (200 query, frozen order 12): median relative error 9.5×10^{-4} , 95th percentile 2.2×10^{-3} , max abs coordinate 2.2×10^{-3} , 通过。

Information 级 (20 panels $\times$ 5 β , order 12): allocation-weighted $\|M_{\text{gold}}^{-1/2}(\widehat{M} - M_{\text{gold}})M_{\text{gold}}^{-1/2}\|_{\text{op}}$ 均值 0.0014、最大 0.0020, 门限 0.05, 通过。

End-to-end ($B = 8000$, 10 paired replications, fast order 14 vs gold adaptive 18): mean $|R_{\text{fast}} - R_{\text{gold}}| = 0.038 \leq 0.15$, 且小于配对 SE 0.017, 通过 (L2-e2e)。

RISK-2/3 (经验 k NN): information fidelity 与 C2ST-vs-ref_val 通过。C2ST vs drifted target 接近 1, 不作为开门条件。